

# 机器学习在图像识别中的应用

# 图像处理和机器学习有什么关系？

**很多公司招聘上，对某些技术岗位要求是“熟悉图像处理或机器学习”，这两者有什么关系？**

图像处理有很多不同的方面，诸如图像增强、图像同质化、图像分割等等。模式识别有时候也归入图像处理里面。

机器学习的主要内容是归纳（Generalization），是根据特征把两个或多个不同的东西区分开来。

在图像处理中，经常有工作是可以人工标记，但难以写出一个完整的规则来实现自动处理。有时候有一整套算法，但是参数太多，人工去调节、寻找合适的参数就太过繁琐。那么就可以利用机器学习的方法，提取一定数量的特征，人工标记一批结果，然后用机器学习的方法算出一套自动判断的准则。机器学习的方法在开发这类软件时就显得比较有效。比如做图像分割时，我们要把大脑的MRI图像和骨骼分开，虽然一般时候这两者是比较清晰的，但总有那么一些时候有些部分不容易简单判别。如果人工来做，实在太耗时耗力。那么究竟一个部分是属于大脑还是属于骨骼，就可以通过机器学习来进行。

# 图像处理和机器学习有什么关系？

再比如说，有一些工作需要把眼球的图像中的血管全部提取出来，然后通过血管的密集程度、粗细来分析病情。照片中血管未必是完全相连的，有的地方可能略微模糊，孤立地看不见得能确定是不是相连的。这时候也可以用机器学习的方法来判定这个部分是不是相连的血管。

图像处理这个概念在工业界很泛泛：

从广义上可以分成，图像处理，图像分析，图像理解。

1. 图像处理(Image processing):数字信号处理的分支领域，属于对图像的底层操作，诸如滤波，去噪，去马赛克去水印(恢复)，压缩，边缘检测。其目的在于设计一种普世算法/滤波器对图像进行一系列预处理，以达到使图像更为美观或更利于后续处理的目的

2. 图像分析:属于中层的图像工程，诸如图像分割，图像边缘提取，这个领域可以认为是在图像处理的基础上引入了部分图像的内容信息来进行研究。比图像处理更为智能一些，因为其已经涉及了从图像中抓取信息了，这点是图像处理所不具备的

3. 图像理解(Image understanding):其实就是计算机视觉，主要是特征提取以及从图像中抓取深层次的语义信息，诸如人脸检测与识别，动作识别，视频的跟踪，行为识别，还有结合图形学的3D重建等。这个领域的目的在于抓取深层次的语义信息，其中识别相关的领域都属于模式识别领域。

# 图像处理和机器学习有什么关系？

对于机器学习，其是一种方法。可以用于上述三个图像领域的任何一个：

1. 图像处理:图像增强，图像恢复都属于智能信息处理领域的研究点之一，除了基于传统的DSP方法外，机器学习在这个领域非常吃香，尤其是图像恢复。近几年图像水印也尝试用机器学习寻找水印的最优嵌入位置。

2. 图像分析与理解:既然涉及了信息提取，机器学习自然会在这些领域大放异彩，例如图像分割，早年有基于数字信号处理的边缘检测和分水岭算法，但是近今年基于深度学习的图像语义分割无疑成为了分割的主流。图像理解作为根正苗红的模式识别行业，框架上就不可能摆脱机器学习。

总结就是，图像工程是领域。机器学习是方法，只是机器学习是图像领域比较热且work的方法

# 什么是机器学习？---从样本中学习的智能程序

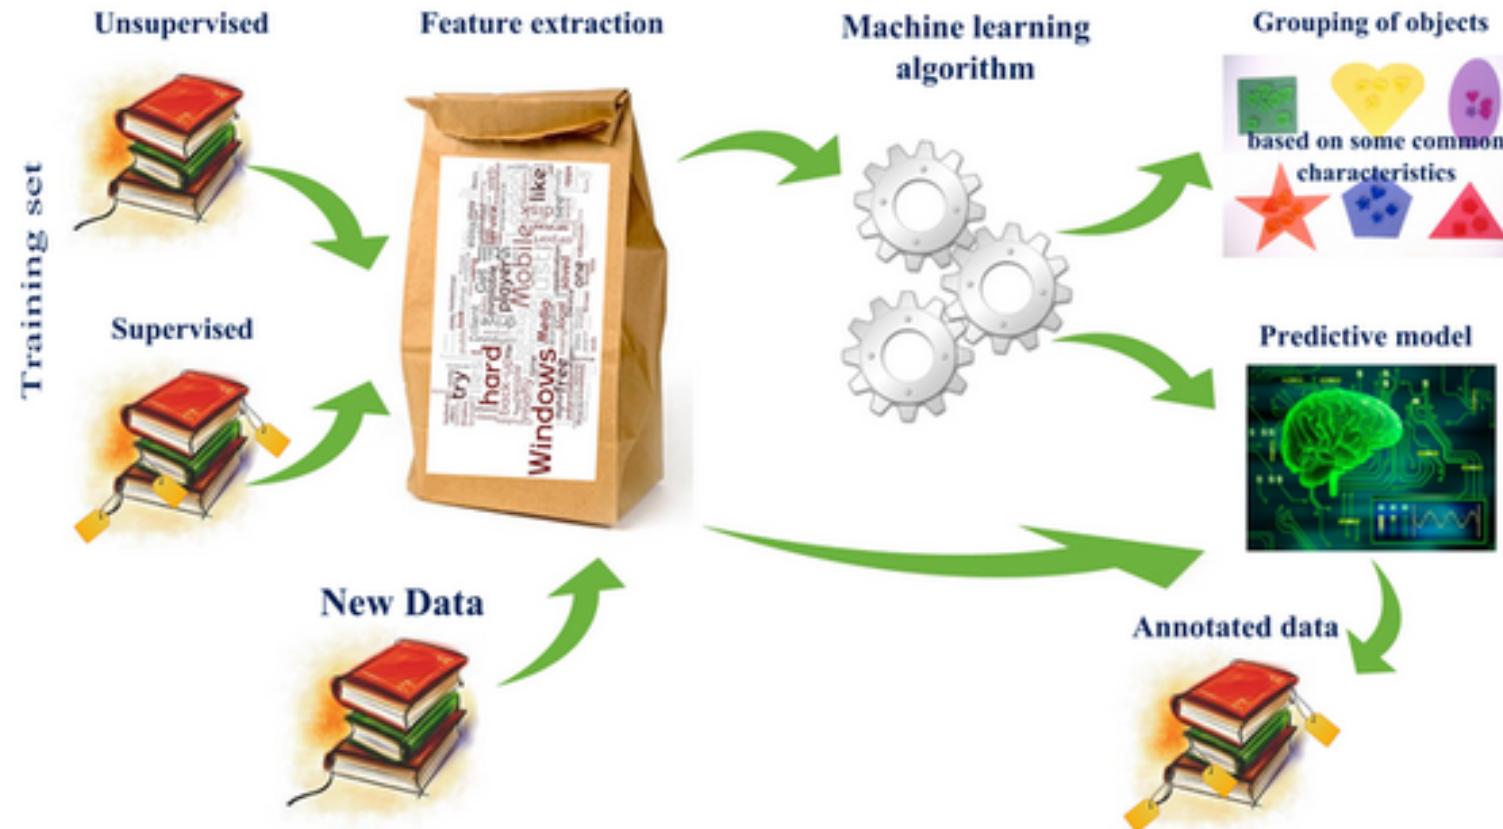
机器通过分析大量数据来进行学习。比如说，不需要通过编程来识别猫或人脸，它们可以通过使用图片来进行训练，从而归纳和识别特定的目标。

在90年代初，人们开始意识到一种可以更有效地构建模式识别算法的方法，那就是用数据（可以通过廉价劳动力采集获得）去替换专家（具有很多图像方面知识的人）。因此，我们搜集大量的人脸和非人脸图像，再选择一个算法，然后冲着咖啡、晒着太阳，等着计算机完成对这些图像的学习。这就是机器学习的思想。“机器学习”强调的是，在给计算机程序（或者机器）输入一些数据后，它必须做一些事情，那就是学习这些数据，而这个学习的步骤是明确的。相信我，就算计算机完成学习要耗上一天的时间，也会比你邀请你的研究伙伴来到你家然后专门手工得为这个任务设计一些分类规则要好。

在21世纪中期，机器学习成为了计算机科学领域一个重要的研究课题，计算机科学家们开始将这些想法应用到更大范围的问题上，不再限于识别字符、识别猫和狗或者识别图像中的某个目标等等这些问题。研究人员开始将机器学习应用到机器人（强化学习，操控，行动规划，抓取）、基因数据的分析和金融市场的预测中。另外，机器学习与图论的联姻也成就了一个新的课题---图模型。每一个机器人专家都“无奈地”成为了机器学习专家，同时，机器学习也迅速成为了众人渴望的必备技能之一。然而，“机器学习”这个概念对底层算法只字未提。我们已经看到凸优化、核方法、支持向量机和Boosting算法等都有各自辉煌的时期。再加上一些人工设计的特征，那在机器学习领域，我们就有了很多的方法，很多不同的思想流派，然而，对于一个新人来说，对特征和算法的选择依然一头雾水，没有清晰的指导原则。

# 什么是机器学习？---典型的机器学习流程

## Machine learning workflow



# 深度学习：一统江湖的架构

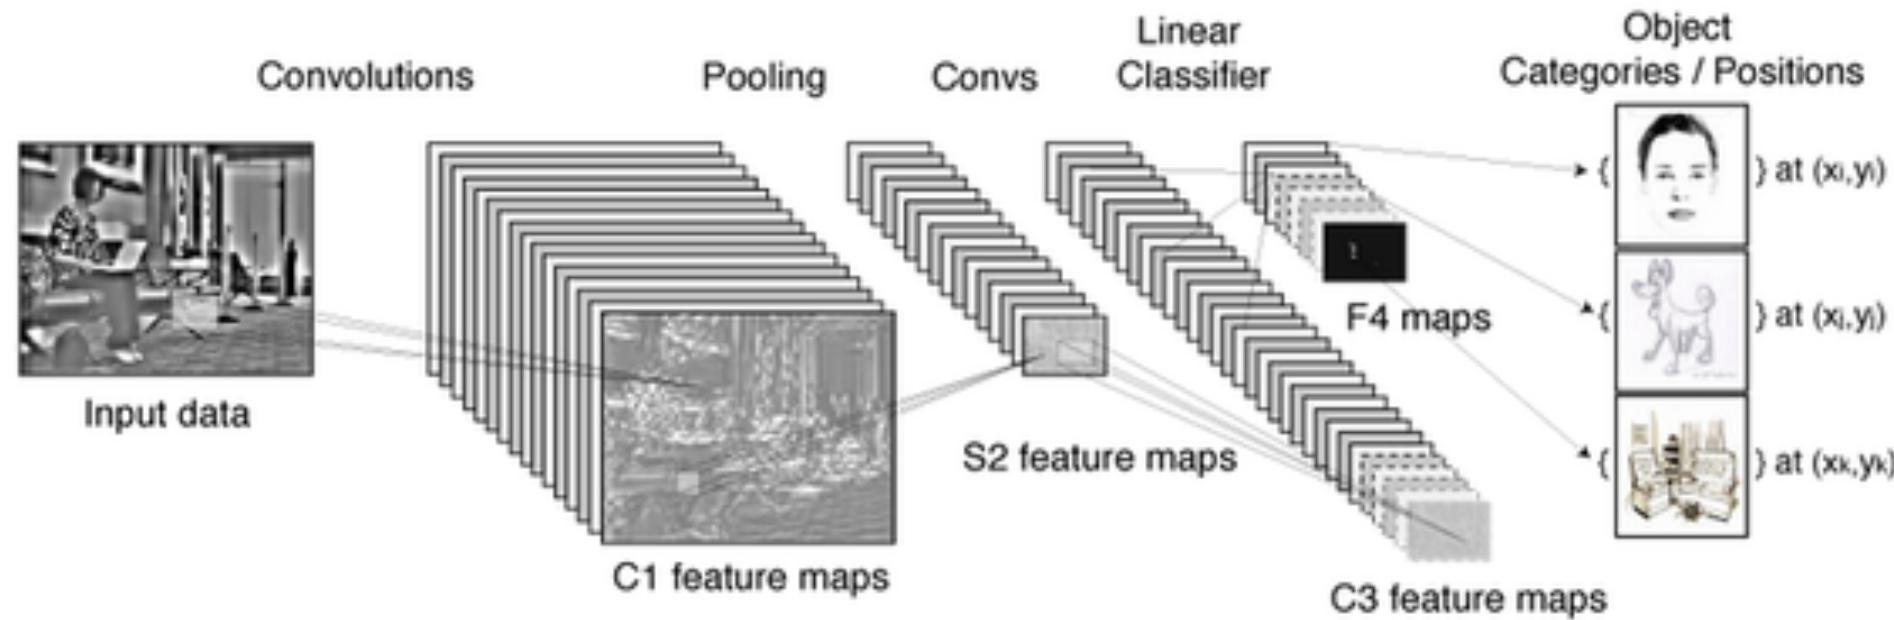
快进到今天，我们看到的是一个夺人眼球的技术---深度学习。而在深度学习的模型中，受宠爱最多的就是被用在大规模图像识别任务中的卷积神经网络（Convolutional Neural Nets, CNN），简称ConvNets。

深度学习强调的是你使用的模型（例如深度卷积多层神经网络），模型中的参数通过从数据中学习获得。然而，深度学习也带来了一些其他需要考虑的问题。因为你面对的是一个高维的模型（即庞大的网络），所以你需要大量的数据（大数据）和强大的运算能力（图形处理器，GPU）才能优化这个模型。卷积被广泛用于深度学习（尤其是计算机视觉应用中），而且它的架构往往都是非浅层的。

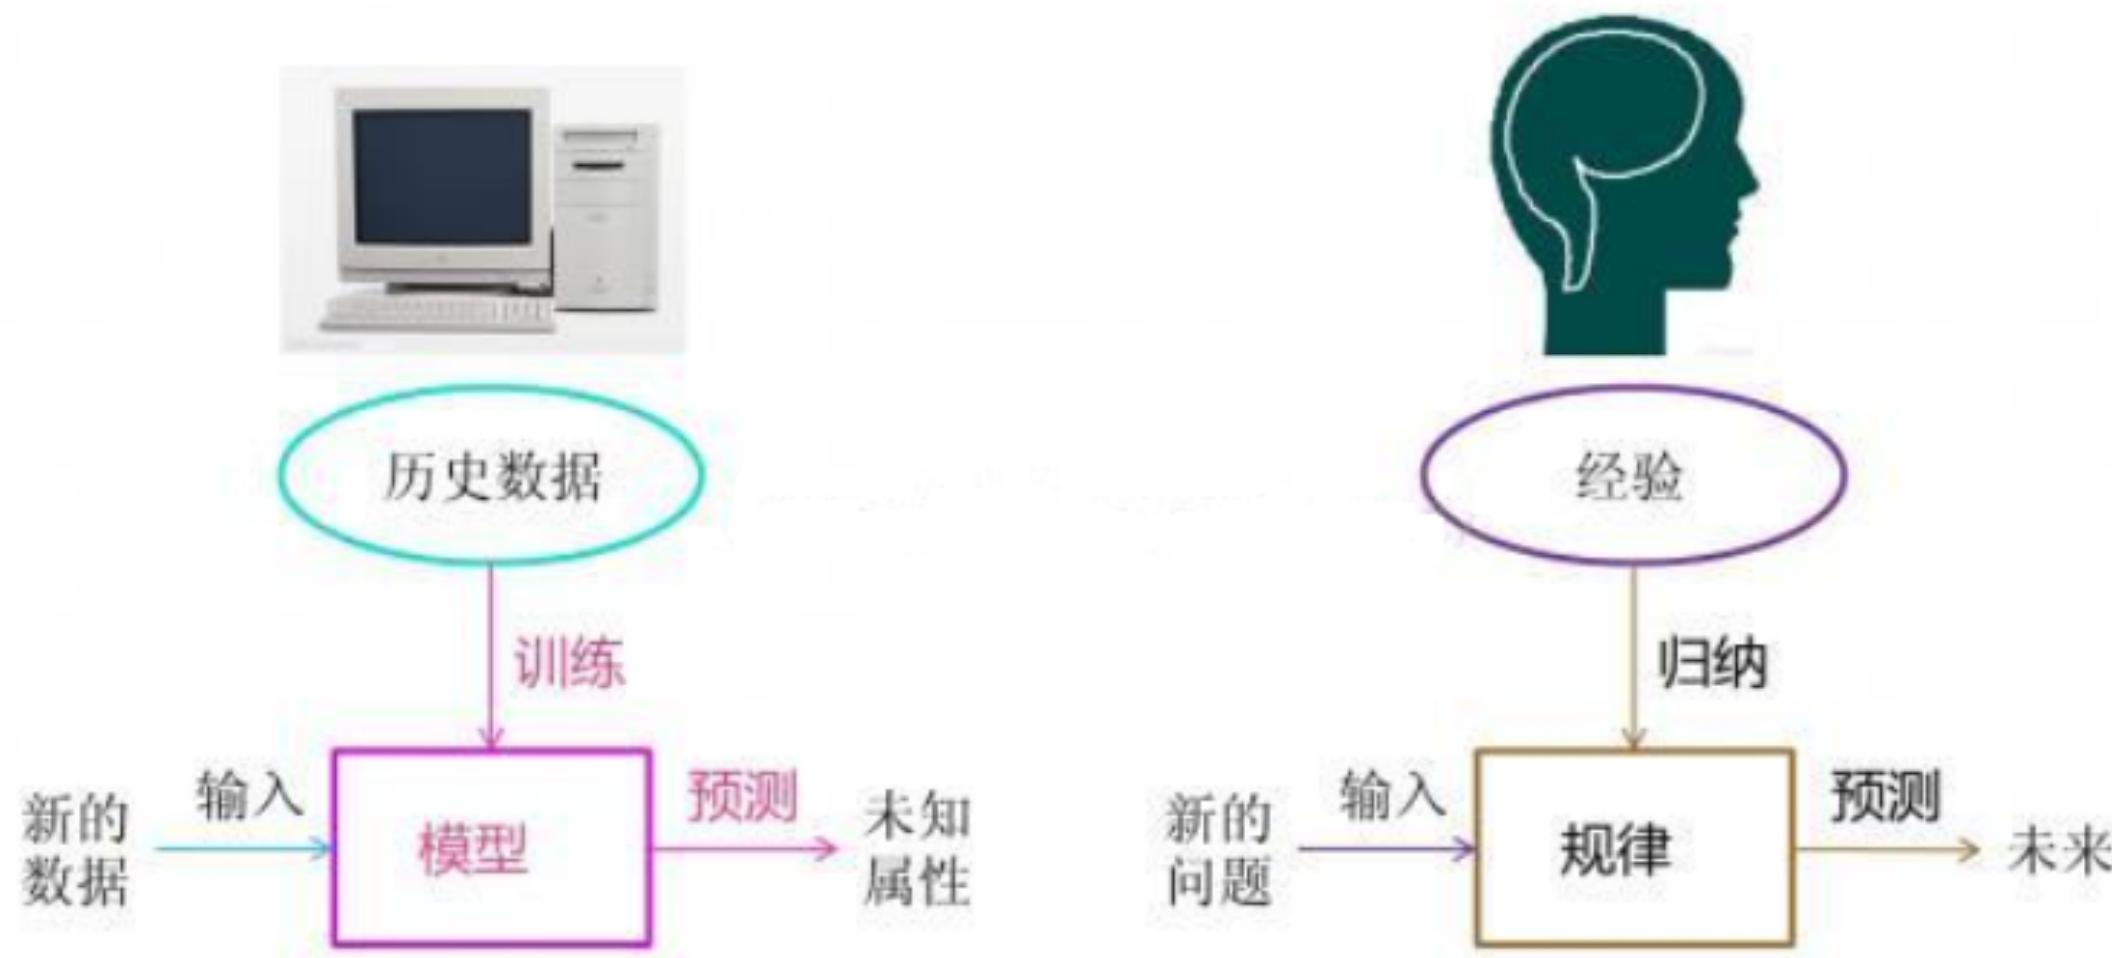
如果你要学习Deep Learning，那就得先复习下一些线性代数的基本知识，当然了，也得有编程基础。另外，作为学习的开端，可以选择一个不用卷积操作的应用问题，然后自己实现基于CPU的反向传播算法。

对于深度学习，还存在很多没有解决的问题。既没有完整的关于深度学习有效性的理论，也没有任何一本能超越机器学习实战经验的指南或者书。另外，深度学习不是万能的，它有足够的理由能日益流行，但始终无法接管整个世界。不过，只要你不断增加你的机器学习技能，你的饭碗无忧。但也不要对深度框架过于崇拜，不要害怕对这些框架进行裁剪和调整，以得到和你的学习算法能协同工作的软件框架。未来的Linux内核也许会在Caffe（一个非常流行的深度学习框架）上运行，然而，伟大的产品总是需要伟大的愿景、领域的专业知识、市场的开发，和最重要的：人类的创造力。

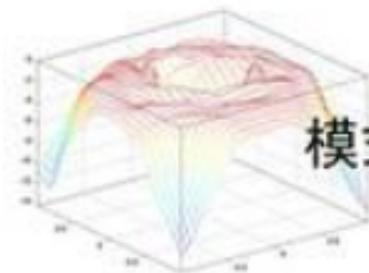
# 深度学习：一统江湖的架构



# 机器学习与人类对历史经验的归纳(人类思考) , 类比图如下



# 机器学习所牵扯的相关范围的学科与研究领域



模式识别



计算机视觉



数据挖掘



机器学习



统计学习



语音识别



自然语言处理

# 下面逐个介绍机器学习与各领域之间的关系

模式识别=机器学习。一个源自工业界，一个源自计算机学科。

数据挖掘=机器学习+数据库。大部分数据挖掘算法，是机器学习算法在数据库中的优化。

统计学习~=机器学习。一个偏数学，一个偏实践。

计算机视觉=机器学习+图像处理。图像处理负责给机器学习模型提供输入，机器学习负责学习并给出视觉结果。

语音识别=语音处理+机器学习。语音识别负责给机器学习模型提供输入，一般语音识别和自然语言处理技术结合使用。

自然语言处理=文本处理+机器学习。

# 什么是图像识别？

图像识别是什么？

以一张图像为例，第一个问题是：在这个图像里面有没有街灯。在学术研究中，我们把这个问题叫作图像检测。

第二个问题就是把街灯的位置给找出来，这叫做定位。

第三个问题是物体的分类和识别，指出这是山，这是树，这个是招牌，建筑。

我们可能还会对整张图片做一个场景的分类，是在什么环境下拍照的。它可能是一个室外的图像，关于城市的生活等等。基本上这些就是我们在图像识别里面涉及到的一些可能的研究问题。

# 图像识别有什么应用?

做这些研究可以有哪些用途?比如无人驾驶汽车:如果汽车上有一个带有摄像头的辅助系统,能够识别这个场景下所有的情况,包括车道线,交通标识,障碍物等,这样能够让我们驾驶汽车更方便、更轻松。

另外,一些相机在拍照的时候,在用户摁下快门到一半的时候,相机就会去找到这个图像的人脸在什么地方。找到人脸以后把焦点对焦在脸上,使这个图像能够让人更清楚一点。

还有,我们的计算机里面往往会有成千上万的照片,怎么组织它们,从而用户快速找到一张照片?如果有这样的图像识别系统,我可能会告诉计算机,我要找的照片里有两个人,这个照片是在颐和园照的。

# 图像识别的困难在哪里？

图像识别有很多难点。第一个困难就是它的视点变化很多。当我们对同样一个物体拍照的时候，因为视点不同，得到的图像外观是不一样的。所以对同一个物体这样看或者那样看，看外观非常不一样。但是也许两个不同的物体，外观又可能会很相近。所以这是造成图像识别的一个困难。

第二个难点就是尺度问题。物体在图像中近大远小，这给我们做图像识别会带来一定的难度。

光影的变化一向是计算机视觉特别关心的一个问题，光影变化是图像识别的第三个难点。同样一个人在不同光影下看起来判若两人。

第四个难点是背景复杂。在复杂背景下，找到某一个人带着拐杖，找到一个戴帽子的人难度很大。

第五个难点是遮挡。遮挡是计算机视觉特别关心的一个难点。比如说，这个图片里熙熙攘攘的人中，我们知道这大概是一个女孩：她有棕色的头发，穿着一个短袖衫。我们人的本领很强，这种情况下还能识别出男女。但是计算机现在还做不到这一点。

第六个难点是变形。非刚体在运动的时候会产生变形。同样一匹马在不同的情况下的图像表现会非常不一样。

# 图像识别的发展历史

图像识别刚开始的时候是从单一的物体识别做起。我们的客观世界那么复杂、那么多样，我们该怎么做识别呢？那就先从特别简单的问题做起。比如从做积木的识别入手。因为积木有很规范的几种形状。这些人造的非常规范的几何体的组合，只要识别出长方形、矩形、正方形、三角形等，就会把积木检测和识别得非常好。

另外一种方法，是根据外观识别。我不考虑要识别的物体的几何结构，仅仅看它外观长什么样。这里列出的是做人脸检测的例子。做人脸识别的研究历史相对比较长。大概七几年就开始有这样的研究工作了。直到现在仍然有很多人脸识别的研究工作发表。

另外一个课题就是手写数字识别。手写数字看起来是很简单的事，但是对手写数字识别的研究引发出相当多的研究方法，给我们带来很多的成果，是一个很有意思的课题。

此外的课题还有汽车的检测。其实同时期还有指纹识别、文字识别OCR等等。当时有的研究工作已经发展到了产品化的程度，包括OCR和指纹识别。

在2000年之前的图像识别曾经采用过几何的方法、结构的方法、规则的方法，当然也用了一些比较简单的模式识别的方法。

# 图像识别的发展历史

在80年代后期、90年代期间，机器学习领域发生了什么？这个时期的机器学习有了一个飞速的发展，出现了一些了不起的研究成果，包括：支持向量机方法，AdaBoosting方法，计算学习理论等成果出现。这些都使得机器学习和识别大大的往前走。

在2002年后的一段时间里，一个华人女科学家，叫李飞飞，开始用一个新的思路做图像识别。他们希望设计一个统一的框架做图像识别，而不是就事论事地针对一种图像识别任务设计一套专门的方法。他们希望这个统一的框架能识别成千上万种物体。另外，希望机器学习领域的出色成果可以用在图像识别上。

她们还借鉴文本分析里的方法-“词袋”(bag of words)的方法用于图像识别。什么是“词袋”方法？举一个例子。比如要识别一张人脸，我们不考虑人脸结构那么复杂，我们只要看看里面有没有鼻子、眼睛、嘴巴、下巴。有了这些部件，只要这些部件在一起，就说这是一张人脸。你可能会觉得这很简单。这个方法来源自对文本的研究。在自然语言处理里面，有一个任务是对文本分类。文本分类中就采用了“词袋”方法。

# 图像识别的发展历史

比如说有这样一篇文章，我们想知道这篇文章是属于哪个类别。它是在讨论军事，还是在讨论科学。那么我们怎么做呢？一种办法是按我们通常会想到的方法，就是把每一句话都读懂，做解析，知道句子的语法结构，然后去理解句子的内容。但是，对句子做语法分析很难，理解句子很难。我们往往做不好，所以就不采用这种方法。实际上，我们可以用一个简单的方法：我们只要看这篇文章出现过哪些词出现的频率高。这篇文章中的高频词是：视觉、感知、脑、神经，细胞，你会说这篇文章属于神经科学类。还有一篇文章，其中的高频词是：中国、贸易、出口、进口、银行、货币等，你会知道这篇文章属于经济类。这个方法不用分析和解析句子和段落的语法结构，而只要把这些高频词放到一块，叫“bag of words”。

怎样把这种方法用于图像识别呢？在识别图像的时候，我们也可以把图像中的“高频词”放在一起识别图像。这里的“词”是什么？直观地说就是小的图像块。比如我们要识别一张人脸，这样的图像上就会有像皮肤一样，或者像眼睛一样的图像块。而相对来说，如果识别自行车，就会出现和车有关的图像块，如：车座、车梁。这些图像块就是“词”。这样就可以采用“词袋”方法。实际上，图像中的词不是我们说的这么直观，而是类似这样的图像小块。它是很底层的图像块，非常小， $3*3$ ,  $5*5$ 或者 $7*7$ 大小的图像块。这样小的图像块不表达很抽象的语义。

# 图像识别的发展历史

这种方法提出后，有很多有意思的相关的论文发表。但是这种方法还有缺陷。我们看这样的几个数字，在图像识别领域有一个物体识别比赛，这个比赛就是给你一些图像，让你去设计和训练你的算法。比赛的时候就是提供一些新的图像，要求算法告诉哪张图片是什么类别。如果预测前5个类别中有标准答案，就算预测正确。否则计算错误。这个比赛在2010年的第一名的成绩是72%，到2011年第一名的成绩是74%。我们知道，全世界那么多优秀的团队，有那么好的资源去做这个事，每年的进步大概就是1%-2%的样子。

在2000年之后这些年，机器学习在做什么事？机器学习仍然是做基础研究，出现了很多优秀成果。其中，2006年Hinton在Science上发表了一篇文章介绍他们的深度学习方法。有人建议Hinton用他们的方法试一试这个物体识别问题。结果在2012年的比赛中，他们获得了第一名，成绩是85%的识别率。后来大家发现这个方法原来那么好，所以大家一拥而上，纷纷用这种方法解决各自关心的问题。为什么人工智能现在这么热？主要就是因为这个原因。

# 面临的困难和今后要研究的问题

看起来图像识别已经很好了，很多人很乐观，很多人热血沸腾。其实图像识别还没有做得那么好。有什么样的困难？我们举几个例子。

比如说我们在做图像识别的时候，通常我们要标注数据，就是要标注这是鸟、这是猫。然后用这些图像去做训练。标注数据其实是很头疼的事，很花时间很花钱。李飞飞的项目组收集的第一个数据集有101类物体。这个图像库做得很好，后来一些算法可以在这个数据库上达到99%多的识别率。人们说，这些图像质量太好了，种类也太少。后来她们又做了一个数据库，这个数据库有256种物体，图像也没有对齐得那么好。尽管这样，这个数据库开始太小。

在2009年李飞飞她们发布了新的数据库ImageNet，大概有几千万张图像数据。

标数据是件头疼的事。例如这个数据库就要对每个物体用一个方框框起来，并给出一个类别标号。这是一些典型的图像，给每个物体都要框起来，都要标好这是什么物体。

还有一个图像数据库叫LabelMe。这种图像，标得非常细，房屋的外形、轮廓、窗户、汽车、所有草地、马路都标得很清楚。大概有十万多张图片，标得非常好的图像大概一万张。

# 面临的困难和今后要研究的问题

因此做机器学习的人就在考虑，能不能不用那么费心去标数据而把图像识别做得更好一点。比如有张图片，只要你就是告诉我，你这张图片有摩托车，你不用说车在哪儿我也能把车检测和识别出来。

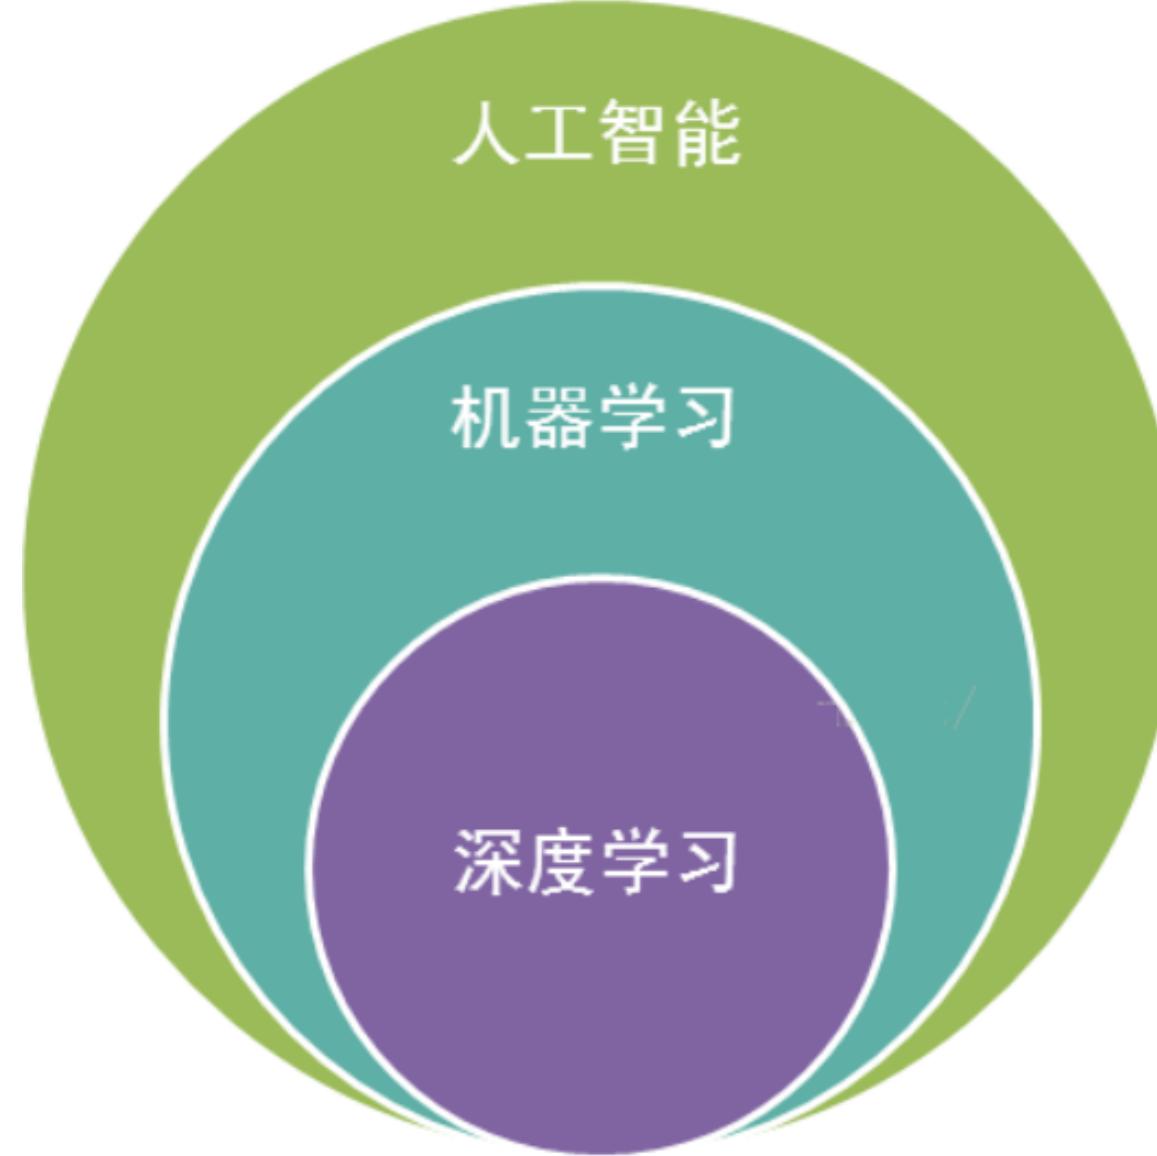
现在还有很多问题没解决。比如说我们现在的技术只是对图像做了一些解析，可以识别出这张图中这个部分鸟、这是树，但是没有对这个图片做更深入的理解。例如：这个算法并不知道这些物体之间的关系是什么。而对于我们理解一张图片来说，理解物体之间的关系非常重要。

现在还有很多很多的问题没有解决。比如，我们现在看深度网络很有效，但是它为什么有效？我们还不太明白。除此之外还有其他的模型吗？比如说有一些工程上的问题，那么多数据你能算吗？机器跑得动吗？做机器学习的人非常关心这些问题。

另外，比如说这里有一束花。现在算法可以识别出这是一束花。但是它还不能说出哪里是叶子，哪里是花蕊，哪里是花瓣。我们看起来已经取得了那么多的成果，从某种意义上来说我们也可以把它们做成产品，让他为我们服务，但同时我们看到还有更多的问题没有解决得很好，这就需要我们继续努力。

这里基本上是在讲图像与图像识别的问题，但是我们看到背后用的很多方法都是机器学习的方法。所以是机器学习人的努力，计算机视觉科学家的努力，大家共同的努力，取得了现在的成果。我们可以用这些成果转化成产品，使我们的生活可以更智能化一点。

# 人工智能、机器学习、深度学习的关系。



# 机器学习对比深度学习

我们先简单讨论下机器学习与深度学习的区别。机器学习一系列在数据集上进行训练的算法，来做出预测或采取行动从而对系统进行优化。例如，基于历史数据，监督分类算法就被用来分类潜在的客户或贷款意向。根据给定任务的不同（例如，监督式聚类），用到的技术也不同：朴素贝叶斯、支持向量机、神经网络、关联规则、决策树、逻辑回归或多种方法之间的结合。

这些都是数据科学的分支。当这些算法被用于自动化的时候，就像在自动飞行或无人驾驶汽车中，它被称为人工智能，更具体的细说，就是深度学习。如果数据收集自传感器，通过互联网进行传输，那就是机器学习或数据科学或深度学习应用到了 IoT 上。

有些人对深度学习有不同的定义。他们认为深度学习是带有更多层的神经网络（神经网络是一种机器学习技术）。深度学习与机器学习的区别这一问题经常被问到，下面对此有详细的解释：

# 机器学习对比深度学习

人工智能是计算机科学的一个子领域，创造于 20 世纪 60 年代，它涉及到解决对人类而言简单却对计算机很难的任务。详细来说，所谓的强人工智能系统应该是能做人类所能做的任何事。这是相当通用的，包含所有的任务，比如规划、到处移动、识别物体与声音、说话、翻译、完成社会或商业事务、创造性的工作（绘画、作诗）等。

自然语言处理只是人工智能与语言有关的一部分。

机器学习被认为是人工智能的一方面：给定一些可用离散术语（例如，在一些行为中，那个行为是正确的）描述的人工智能问题，并给出关于这个世界的大量信息，在没有程序员进行编程的情况下弄清楚「正确」的行为。典型的是，需要一些外部流程判断行为是否正确。在数学术语中，也就是函数：馈入输入，产生正确的输出。所以整个问题就是以自动化的方式建立该数学函数的模型。在二者进行区分时：如果我写出的程序聪明到表现出人类行为，它就是人工智能。但如果它的参数不是自动从数据进行学习，它就不是机器学习。

深度学习是如今非常流行的一种机器学习。它涉及到一种特殊类型的数学模型，可认为它是特定类型的简单模块的结合（函数结合），这些模块可被调整从而更好的预测最终输出。

# 大数据与机器学习

大数据指数据量大这种技术；机器学习指利用数据的关键技术。

大数据技术不仅仅指机器学习，还包括：分布式计算、分布式存储、内存数据库redis、多维分析等等。

机器学习指大数据分析的一种技术，一种很好发挥大数据价值，挖掘大数据潜力的技术。

有理论表明：只要数据量足够大，机器学习的预测准确度都相差无几。

# 机器学习和人工智能的关系

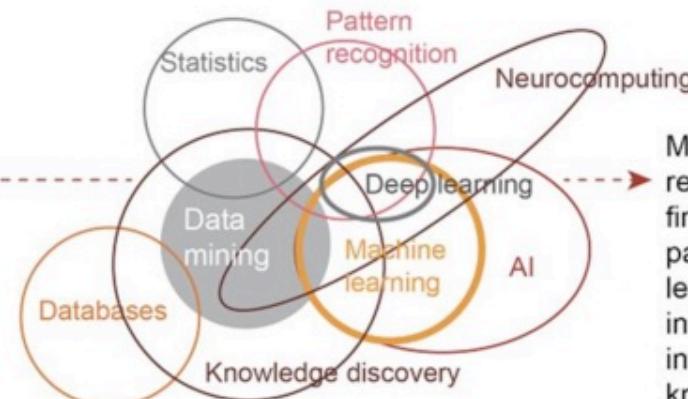
机器学习是一种重在寻找数据中的模式并使用这些模式来做出预测的研究和算法的门类。机器学习是人工智能领域的一部分，并且和知识发现与数据挖掘有所交集。



## What is it?

Machines can "learn" by analyzing large amounts of data. For example, rather than being programmed to recognize a cat or human face, they can be trained with images from which to generalize and recognize specific objects.

## How does machine learning relate to artificial intelligence?



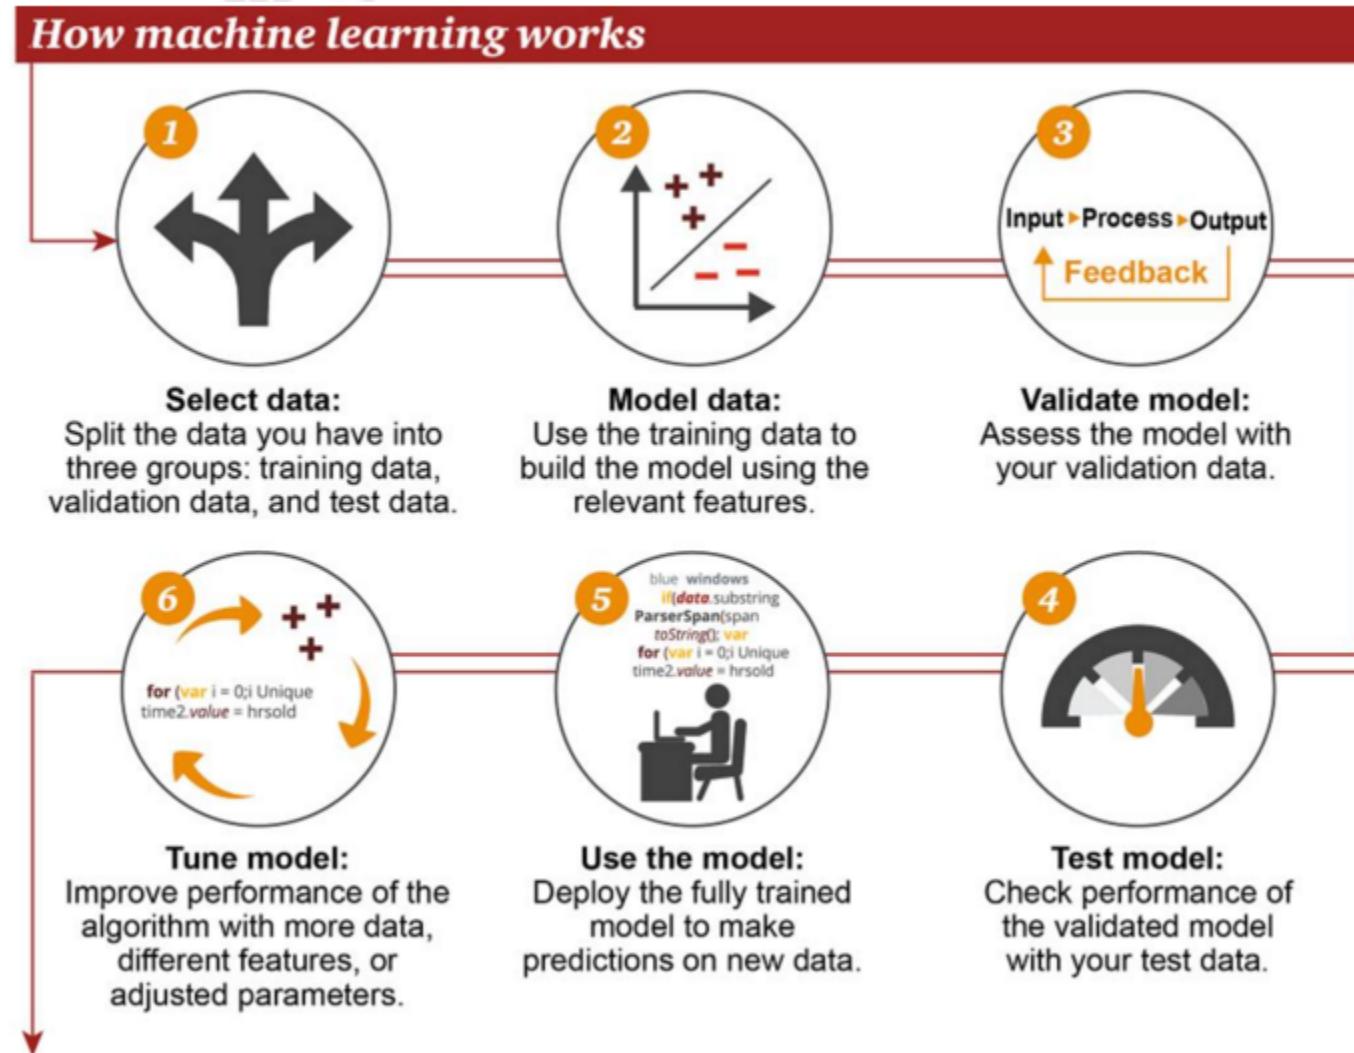
Machine learning is a category of research and algorithms focused on finding patterns in data and using those patterns to make predictions. Machine learning falls within the artificial intelligence (AI) umbrella, which in turn intersects with the broader field of knowledge discovery and data mining.

Source: SAS, 2014 and PwC, 2016

# 机器学习的工作方式

- ① 选择数据：将你的数据分成三组：训练数据、验证数据和测试数据
- ② 模型数据：使用训练数据来构建使用相关特征的模型
- ③ 验证模型：使用你的验证数据接入你的模型
- ④ 测试模型：使用你的测试数据检查被验证的模型的表现
- ⑤ 使用模型：使用完全训练好的模型在新数据上做预测
- ⑥ 调优模型：使用更多数据、不同的特征或调整过的参数来提升算法的性能表现

# 机器学习的工作方式



# 机器学习所处的位置

- ① 传统编程：软件工程师编写程序来解决问题。首先存在一些数据→为了解决一个问题，软件工程师编写一个流程来告诉机器应该怎样做→计算机遵照这一流程执行，然后得出结果
- ② 统计学：分析师比较变量之间的关系
- ③ 机器学习：数据科学家使用训练数据集来教计算机应该怎么做，然后系统执行该任务。首先存在大数据→机器会学习使用训练数据集来进行分类，调节特定的算法来实现目标分类→该计算机可学习识别数据中的关系、趋势和模式
- ④ 智能应用：智能应用使用人工智能所得到的结果，如图是一个精准农业的应用案例示意，该应用基于无人机所收集到的数据

# 机器学习的实际应用

机器学习有很多应用场景，这里给出了一些示例，你会怎么使用它？

快速三维地图测绘和建模：要建造一架铁路桥，数据科学家和领域专家将机器学习应用到了无人机收集到的数据上。这种组合实现了工作成功中的精准监控和快速反馈。

增强分析以降低风险：为了检测内部交易，人们将机器学习和其它分析技术结合了起来，从而开发了更为全面的用户概况，并且获得了对复杂可疑行为的更深度了解。

预测表现最佳的目标：人们使用机器学习和其它分析方法来评估赛场上不同赛马的潜力。

# 机器学习的实际应用

## Machine learning in practice

Here are just a few of the many ways we've put machine learning to work. How will your company use it?



### Rapid 3D mapping and modeling

For a railway bridge reconstruction, PwC data scientists and domain experts applied machine learning to data captured from drones. The combination enabled precise monitoring and quick feedback on work in progress.



### Enhanced profiling to mitigate risks

To detect insider trading, PwC combined machine learning with other analytic techniques to develop more comprehensive user profiles and gain deeper insight into complex suspicious behaviors.



### Predicting the top performers

PwC used machine learning and other analysis to evaluate the potential of different horses running in the Melbourne Cup.

# 机器学习的演化---五大流派

几十年来，人工智能研究者的各个「部落」一直以来都在彼此争夺主导权，现在是这些部落联合起来的时候了吗？他们也可能不得不这样做，因为合作和算法融合是实现真正通用人工智能(AGI)的唯一方式。这里给出了机器学习方法的演化之路以及未来的可能模样。

① 符号主义：使用符号、规则和逻辑来表征知识和进行逻辑推理，最喜欢的算法是：规则和决策树 , **Random Forest, Adaboost (Adaptive Boost)**

② 贝叶斯派：获取发生的可能性来进行概率推理，最喜欢的算法是：朴素贝叶斯或马尔可夫

③ 联结主义：使用概率矩阵和加权神经元来动态地识别和归纳模式，最喜欢的算法是：神经网络 , **LSTM, GRU, etc.**

④ 进化主义：生成变化，然后为特定目标获取其中最优的，最喜欢的算法是：遗传算法

⑤ Analogizer：根据约束条件来优化函数（尽可能走到更高，但同时不要离开道路），最喜欢的算法是：支持向量机 , **KNN**

# 机器学习的演化---五大流派



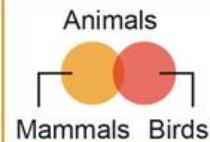
## A look at *Machine learning evolution*

### Overview

For decades, individual “tribes” of artificial intelligence researchers have vied with one another for dominance. Is the time ripe now for tribes to collaborate? They may be forced to, as collaboration and algorithm blending are the only ways to reach true artificial general intelligence (AGI). Here’s a look back at how machine learning methods have evolved and what the future may look like.

### *What are the five tribes?*

#### Symbolists



Use symbols, rules, and logic to represent knowledge and draw logical inference

Favored algorithm  
Rules and decision trees

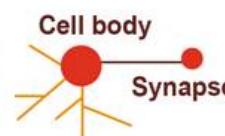
#### Bayesians



Assess the likelihood of occurrence for probabilistic inference

Favored algorithm  
Naive Bayes or Markov

#### Connectionists



Recognize and generalize patterns dynamically with matrices of probabilistic, weighted neurons

Favored algorithm  
Neural networks

#### Evolutionaries



Generate variations and then assess the fitness of each for a given purpose

Favored algorithm  
Genetic programs

#### Analogizers



Optimize a function in light of constraints (“going as high as you can while staying on the road”)

Favored algorithm  
Support vectors

# 机器学习的演化---演化的阶段

1980 年代

主导流派：符号主义

架构：服务器或大型机

主导理论：知识工程

基本决策逻辑：决策支持系统，实用性有限

1990 年代到 2000 年

主导流派：贝叶斯

架构：小型服务器集群

主导理论：概率论

分类：可扩展的比较或对比，对许多任务都足够好了

2010 年代早期到中期

主导流派：联结主义

架构：大型服务器农场

主导理论：神经科学和概率

识别：更加精准的图像和声音识别、翻译、情绪分析等

# 机器学习的演化---这些流派有望合作，并将各自的方法融合到一起

2010 年代末期

主导流派：联结主义+符号主义

架构：许多云

主导理论：记忆神经网络、大规模集成、基于知识的推理

简单的问答：范围狭窄的、领域特定的知识共享

2020 年代+

主导流派：联结主义+符号主义+贝叶斯+.....

架构：云计算和雾计算

主导理论：感知的时候有网络，推理由工作的时候有规则

简单感知、推理由和行动：有限制的自动化或人机交互

2040 年代+

主导流派：算法融合

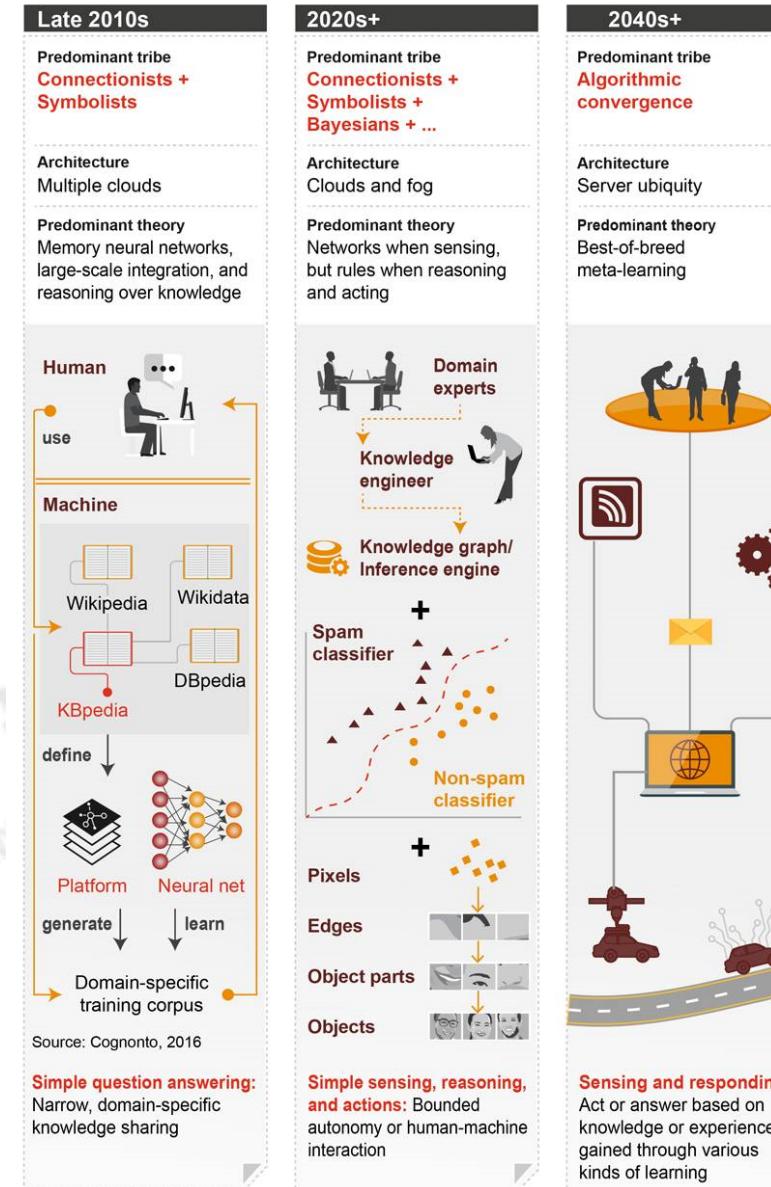
架构：无处不在的服务器

主导理论：最佳组合的元学习

感知和响应：基于通过多种学习方式获得的知识或经验采取行动或做出回答

# 机器学习的演化---这些流派有望合作，并将各自的方法融合到一起

*The tribes see fit to collaborate and blend their methods*



# 机器学习的算法---决策树 ( Decision Tree )

决策树的一大优势就是易于解释。它可以毫无压力地处理特征间的交互关系并且是非参数化的，因此你不必担心异常值或者数据是否线性可分(举个例子，决策树能轻松处理好类别A在某个特征维度x的末端，类别B在中间，然后类别A又出现在特征维度x前端的情况)。它的缺点之一就是不支持在线学习，于是在新样本到来后，决策树需要全部重建。另一个缺点就是容易出现过拟合，但这也就是诸如随机森林RF(或提升树boosted tree)之类的集成方法的切入点。另外，随机森林经常是很多分类问题的赢家(通常比支持向量机好上那么一丁点)，它训练快速并且可调，同时你无须担心要像支持向量机那样调一大堆参数，所以在以前都一直很受欢迎。

决策树中很重要的一点就是选择一个属性进行分枝，因此要注意一下信息增益的计算公式，并深入理解它。

决策树自身的优点:计算简单，易于理解，可解释性强;比较适合处理有缺失属性的样本;能够处理不相关的特征;在相对短的时间内能够对大型数据源做出可行且效果良好的结果。

缺点:容易发生过拟合(随机森林可以很大程度上减少过拟合);忽略了数据之间的相关性;对于那些各类别样本数量不一致的数据，在决策树当中,信息增益的结果偏向于那些具有更多数值的特征(只要是使用了信息增益，都有这个缺点，如RF)。

# 机器学习的算法---决策树 ( Decision Tree )

你应该使用哪种机器学习算法？这在很大程度上依赖于可用数据的性质和数量以及每一个特定用例中你的训练目标。不要使用最复杂的算法，除非其结果值得付出昂贵的开销和资源。这里给出了一些最常见的算法，按使用简单程度排序。

在进行逐步应答过程中，典型的决策树分析会使用分层变量或决策节点，例如，可将一个给定用户分类成信用可靠或不可靠。

优点：擅长对人、地点、事物的一系列不同特征、品质、特性进行评估

场景举例：基于规则的信用评估、赛马结果预测

扩展阅读：

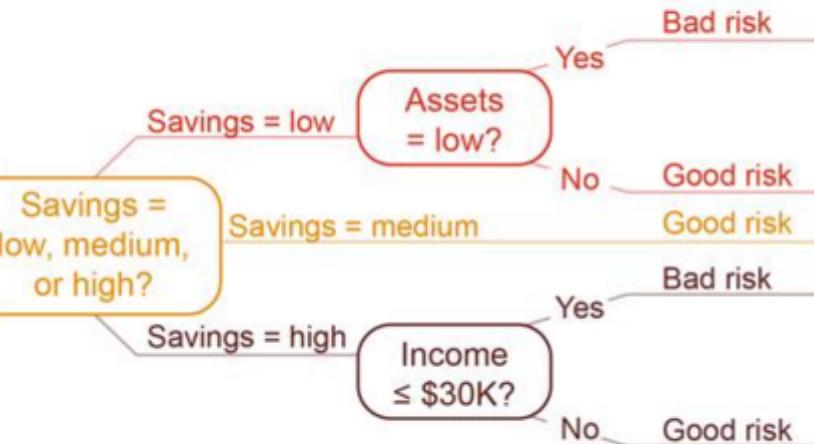
[《教程 | 从头开始：用Python实现决策树算法》](#)、

[《想了解概率图模型？你要先理解图论的基本定义与形式》](#)

# 机器学习的算法---决策树 ( Decision Tree )

## Decision trees

Decision tree analysis typically uses a hierarchy of variables or decision nodes that, when answered step by step, can classify a given customer as creditworthy or not, for example.



### Advantages

Decision trees are useful when evaluating lists of distinct features, qualities, or characteristics of people, places, or things.

### Use cases

Rule-based credit risk assessment, horse race performance prediction

Source: Daniel T. Larose and Chantal D. Larose, *Data Mining and Predictive Analytics*, 2nd Edition, John Wiley & Sons, 2015

# 机器学习的算法---回归 (Regression)

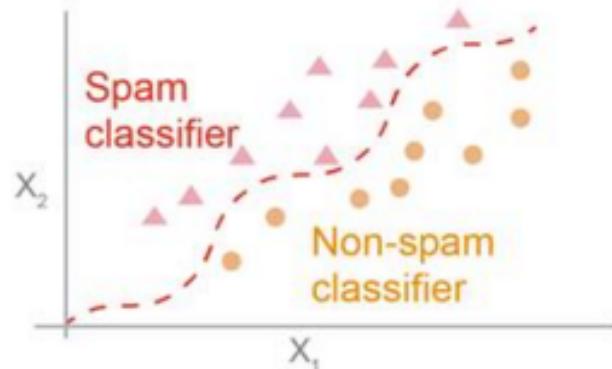
回归可以勾画出因变量与一个或多个因变量之间的状态关系。在这个例子中，将垃圾邮件和非垃圾邮件进行了区分。

优点：回归可用于识别变量之间的连续关系，即便这个关系不是非常明显

场景举例：路面交通流量分析、邮件过滤

## Regression

Regression maps the behavior of a dependent variable relative to one or more dependent variables. In this example, logistic regression separates spam from non-spam text.



### Advantages

Regression is useful for identifying continuous (not necessarily distinct) relationships between variables.

### Use cases

Traffic flow analysis, email filtering

# 机器学习的算法---Logistic Regression(逻辑回归)

逻辑回归属于判别式模型，同时伴有很多模型正则化的方法(L0, L1, L2, etc)，而且你不必像在用朴素贝叶斯那样担心你的特征是否相关。与决策树、SVM相比，你还会得到一个不错的概率解释，你甚至可以轻松地利用新数据来更新模型(使用在线梯度下降算法-online gradient descent)。如果你需要一个概率架构(比如，简单地调节分类阈值，指明不确定性，或者是要获得置信区间)，或者你希望以后将更多的训练数据快速整合到模型中去，那么使用它吧。

优点：实现简单，广泛的应用于工业问题上;分类时计算量非常小，速度很快，存储资源低;便利的观测样本概率分数;对逻辑回归而言，多重共线性并不是问题，它可以结合L2正则化来解决该问题;

缺点：当特征空间很大时，逻辑回归的性能不是很好;容易欠拟合，一般准确度不太高不能很好地处理大量多类特征或变量;只能处理两分类问题(在此基础上衍生出来的softmax可以用于多分类)，且必须线性可分;对于非线性特征，需要进行转换;

# 机器学习的算法---线性回归

线性回归是用于回归的，它不像Logistic回归那样用于分类，其基本思想是用梯度下降法对最小二乘法形式的误差函数进行优化，当然也可以用normal equation直接求得参数的解，结果为：

$$\hat{w} = (X^T X)^{-1} X^T y$$

而在LWLR(局部加权线性回归)中，参数的计算表达式为：

$$\hat{w} = (X^T W X)^{-1} X^T W y$$

由此可见LWLR与LR不同，LWLR是一个非参数模型，因为每次进行回归计算都要遍历训练样本至少一次。

优点：实现简单，计算简单；

缺点：不能拟合非线性数据。

# 机器学习的算法---最近邻算法 ( KNN )

KNN即最近邻算法，其主要过程为：

1. 计算训练样本和测试样本中每个样本点的距离(常见的距离度量有欧式距离，马氏距离等);
2. 对上面所有的距离值进行排序(升序);
3. 选前k个最小距离的样本;
4. 根据这k个样本的标签进行投票，得到最后的分类类别;

如何选择一个最佳的K值，这取决于数据。一般情况下，在分类时较大的K值能够减小噪声的影响，但会使类别之间的界限变得模糊。一个较好的K值可通过各种启发式技术来获取，比如，交叉验证。另外噪声和非相关性特征向量的存在会使K近邻算法的准确性减小。近邻算法具有较强的一致性结果，随着数据趋于无限，算法保证错误率不会超过贝叶斯算法错误率的两倍。对于一些好的K值，K近邻保证错误率不会超过贝叶斯理论误差率。

KNN算法的优点:理论成熟，思想简单，既可以用来做分类也可以用来做回归;可用于非线性分类;训练时间复杂度为 $O(n)$ ;对数据没有假设，准确度高，对outlier不敏感;

缺点:计算量大(体现在距离计算上);样本不平衡问题(即有些类别的样本数量很多，而其它样本的数量很少)效果差;需要大量内存;

# 机器学习的算法---朴素贝叶斯分类 ( Naive Bayes Classification )

朴素贝叶斯属于生成式模型(关于生成模型和判别式模型，主要还是在于是否需要求联合分布)，比较简单，你只需做一堆计数即可。如果注有条件的独立性假设(一个比较严格的条件)，朴素贝叶斯分类器的收敛速度将快于判别模型，比如逻辑回归，所以你只需要较少的训练数据即可。即使NB条件独立假设不成立，NB分类器在实践中仍然表现的很出色。它的主要缺点是它不能学习特征间的相互作用，用mRMR中R来讲，就是特征冗余。引用一个比较经典的例子，比如，虽然你喜欢Brad Pitt和Tom Cruise的电影，但是它不能学习出你不喜欢他们在一起演的电影。

优点：朴素贝叶斯模型发源于古典数学理论，有着坚实的数学基础，以及稳定的分类效率。对小规模的数据表现很好，能处理多分类任务，适合增量式训练;对缺失数据不太敏感，算法也比较简单，常用于文本分类。

缺点：需要计算先验概率;分类决策存在错误率;对输入数据的表达形式很敏感。

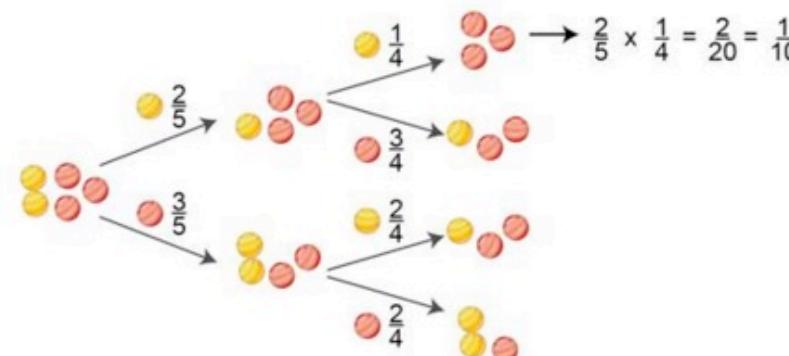
# 机器学习的算法---朴素贝叶斯分类 ( Naive Bayes Classification )

朴素贝叶斯分类器用于计算可能条件的分支概率。每个独立的特征都是「朴素」或条件独立的，因此它们不会影响别的对象。例如，在一个装有共 5 个黄色和红色小球的罐子里，连续拿到两个黄色小球的概率是多少？从图中最上方分支可见，前后抓取两个黄色小球的概率为 1/10。朴素贝叶斯分类器可以计算多个特征的联合条件概率。

场景举例：情感分析、消费者分类

## Naive Bayes classification

Naive Bayes classifiers compute probabilities, given tree branches of possible conditions. Each individual feature is “naive” or conditionally independent of, and therefore does not influence, the others. For example, what’s the probability you would draw two yellow marbles in a row, given a jar of five yellow and red marbles total? The probability, following the topmost branch of two yellow in a row, is one in ten. Naive Bayes classifiers compute the combined, conditional probabilities of multiple attributes.



### Advantages

Naive Bayes methods allow the quick classification of relevant items in small data sets that have distinct features.

### Use cases

Sentiment analysis, consumer segmentation

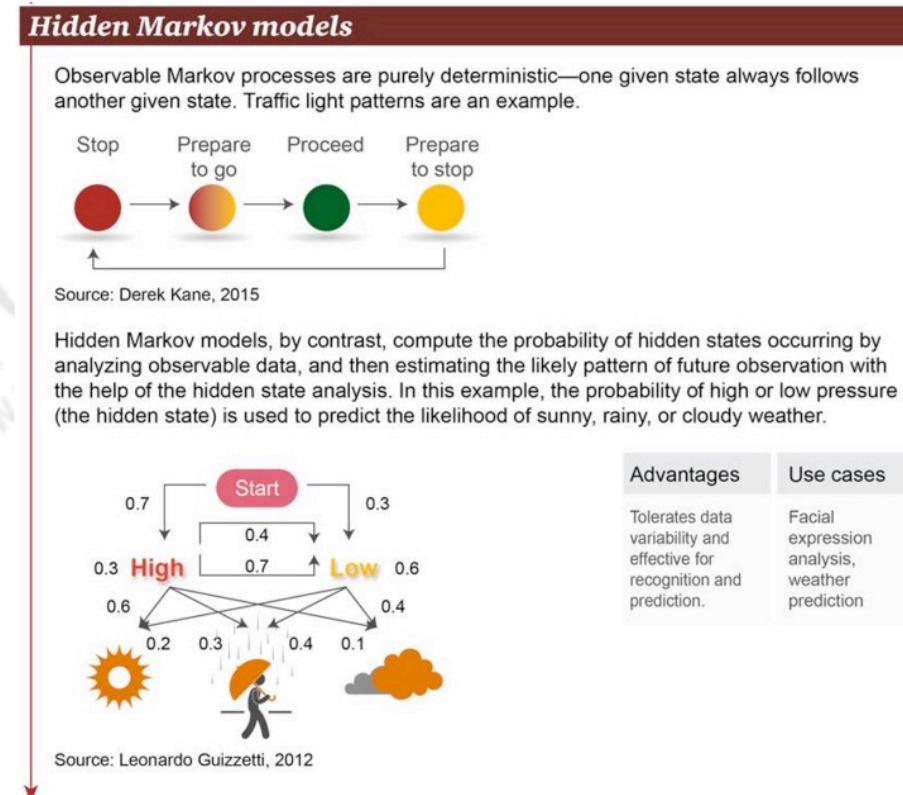
Source: Rod Pierce, et al., *MathIsFun*, 2014

# 机器学习的算法---隐马尔可夫模型 (Hidden Markov model)

显马尔可夫过程是完全确定性的——一个给定的状态经常会伴随另一个状态。交通信号灯就是一个例子。相反，隐马尔可夫模型通过分析可见数据来计算隐藏状态的发生。随后，借助隐藏状态分析，隐马尔可夫模型可以估计可能的未来观察模式。在本例中，高或低气压的概率（这是隐藏状态）可用于预测晴天、雨天、多云天的概率。

优点：容许数据的变化性，适用于识别（recognition）和预测操作

场景举例：面部表情分析、气象预测



# 机器学习的算法---随机森林 ( Random forest )

随机森林算法通过使用多个带有随机选取的数据子集的树 (tree) 改善了决策树的精确性。本例在基因表达层面上考察了大量与乳腺癌复发相关的基因，并计算出复发风险。

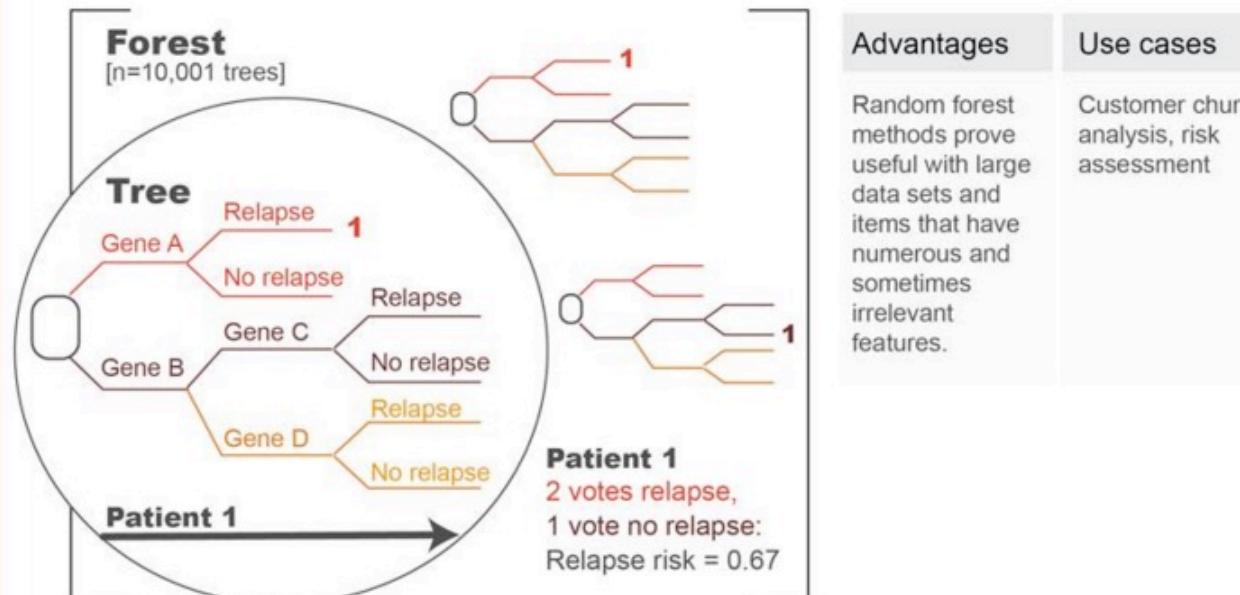
优点：随机森林方法被证明对大规模数据集和存在大量且有时不相关特征的项 (item) 来说很有用

场景举例：用户流失分析、风险评估

扩展阅读：《教程 | 从头开始：用 Python 实现随机森林算法》

## Random forest

Random forest algorithms improve the accuracy of decision trees by using multiple trees with randomly selected subsets of data. This example reviews the expression levels of various genes associated with breast cancer relapse and computes a relapse risk.



Source: Nicolas Spies, Washington University, 2015

# 机器学习的算法---循环神经网络 ( Recurrent neural network )

在任意神经网络中，每个神经元都通过 1 个或多个隐藏层来将很多输入转换成单个输出。循环神经网络（RNN）会将值进一步逐层传递，让逐层学习成为可能。换句话说，RNN 存在某种形式的记忆，允许先前的输出去影响后面的输入。

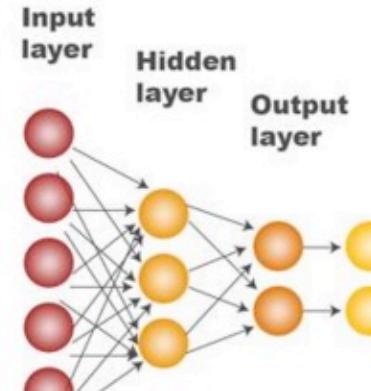
优点：循环神经网络在存在大量有序信息时具有预测能力

场景举例：图像分类与字幕添加、政治情感分析

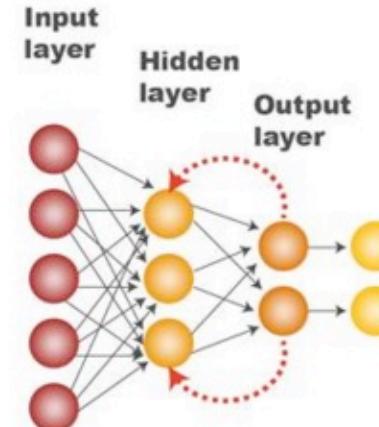
## Recurrent neural networks

Each neuron in any neural network converts many inputs into single outputs via one or more hidden layers. Recurrent neural networks [RNNs] additionally pass values from step to step, making step-by-step learning possible. In other words, RNNs have a form of memory, allowing previous outputs to affect subsequent inputs.

Non-recurrent feed-forward neural network



Recurrent neural network—includes loops



### Advantages

Recurrent neural networks have predictive power when used with large amounts of sequenced information.

### Use cases

Image classification and captioning, political sentiment analysis

# 机器学习的算法---长短期记忆与门控循环单元神经网络

早期的 RNN 形式是会存在损耗的。尽管这些早期循环神经网络只允许留存少量的早期信息，新近的长短期记忆（LSTM）与门控循环单元（GRU）神经网络都有长期与短期的记忆。换句话说，这些新近的 RNN 拥有更好的控制记忆的能力，允许保留早先的值或是当有必要处理很多系列步骤时重置这些值，这避免了「梯度衰减」或逐层传递的值的最终 degradation。LSTM 与 GRU 网络使得我们可以使用被称为「门（gate）」的记忆模块或结构来控制记忆，这种门可以在合适的时候传递或重置值。

优点：长短期记忆和门控循环单元神经网络具备与其它循环神经网络一样的优点，但因为它们有更好的记忆能力，所以更常被使用

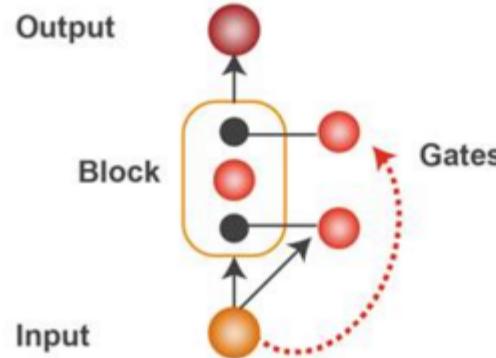
场景举例：自然语言处理、翻译

扩展阅读：《深度 | LSTM 和递归网络基础教程》和《干货 | 图解 LSTM 神经网络架构及其 11 种变体（附论文）》

# 机器学习的算法---长短期记忆与门控循环单元神经网络

## ***Long short-term memory & gated recurrent unit neural networks***

Older forms of RNNs can be lossy. While these older recurrent neural networks only allow small amounts of older information to persist, newer long short-term memory (LSTM) and gated recurrent unit (GRU) neural networks have both long- and short-term memory. In other words, these newer RNNs have greater memory control, allowing previous values to persist or to be reset as necessary for many sequences of steps, avoiding “gradient decay” or eventual degradation of the values passed from step to step. LSTM and GRU networks make this memory control possible with memory blocks and structures called gates that pass or reset values as appropriate.



Source: Genevieve Orr, et al., Willamette University, 1999

### Advantages

Long short-term memory and gated recurrent unit neural networks have the same advantages as other recurrent neural networks and are more frequently used than other recurrent neural networks because of their greater memory capabilities.

### Use cases

Natural language processing, translation

# 机器学习的算法---Adaboosting

Adaboost是一种加和模型，每个模型都是基于上一次模型的错误率来建立的，过分关注分错的样本，而对正确分类的样本减少关注度，逐次迭代之后，可以得到一个相对较好的模型。

优点：

Adaboost是一种有很高精度的分类器。可以使用各种方法构建子分类器，Adaboost算法提供的是框架。当使用简单分类器时，计算出的结果是可以理解的，并且弱分类器的构造极其简单，不用做特征筛选。不易发生过度拟合。

缺点：对异常值比较敏感

# 机器学习的算法---支持向量机 ( Support Vector Machine )

支持向量机，一个经久不衰的算法，高准确率，为避免过拟合提供了很好的理论保证，而且就算数据在原特征空间线性不可分，只要给个合适的核函数，它就能运行得很好。在动辄超高维的文本分类问题中特别受欢迎。可惜内存消耗大，难以解释，运行和调参也有些烦人，而随机森林却刚好避开了这些缺点，比较实用。

优点:可以解决高维问题，即大型特征空间;能够处理非线性特征的相互作用;无需依赖整个数据;可以提高泛化能力;

缺点:当观测样本很多时，效率并不是很高;对非线性问题没有通用解决方案，有时候很难找到一个合适的核函数;对缺失数据敏感;

对于核的选择也是有技巧的(libsvm中自带了四种核函数：线性核、多项式核、RBF以及sigmoid核)：

第一，如果样本数量小于特征数，那么就没必要选择非线性核，简单的使用线性核就可以了；

第二，如果样本数量大于特征数目，这时可以使用非线性核，将样本映射到更高维度，一般可以得到更好的结果；

第三，如果样本数目和特征数目相等，该情况可以使用非线性核，原理和第二种一样。

对于第一种情况，也可以先对数据进行降维，然后使用非线性核，这也是一种方法。

# 机器学习的算法---支持向量机 ( Support Vector Machine )

基于超平面 (hyperplane) , 支持向量机可以对数据群进行分类。

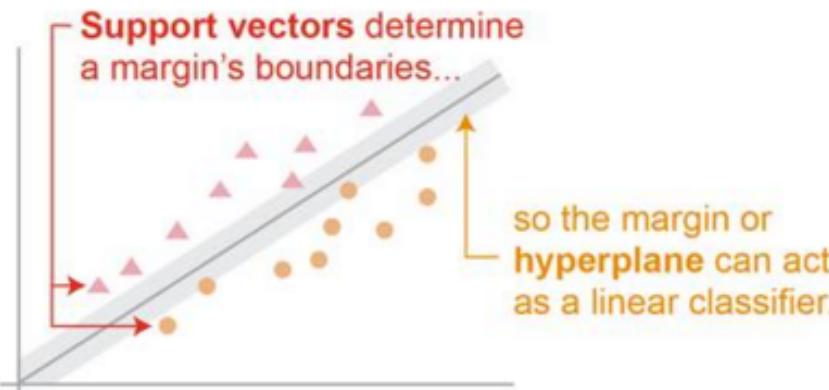
优点：支持向量机擅长在变量 X 与其它变量之间进行二元分类操作，无论其关系是否是线性的

场景举例：新闻分类、手写识别。

扩展阅读：《干货 | 详解支持向量机（附学习资源）》

## Support vector machines

Support vector machines classify groups of data with the help of hyperplanes.



Source: Matthew Kelly, Computer Science: Source, 2010

### Advantages

Support vector machines are good for the binary classification of X versus other variables and are useful whether or not the relationship between variables is linear.

### Use cases

News categorization, handwriting recognition

# 机器学习的算法---卷积神经网络 ( convolutional neural network )

卷积是指来自后续层的权重的融合，可用于标记输出层。

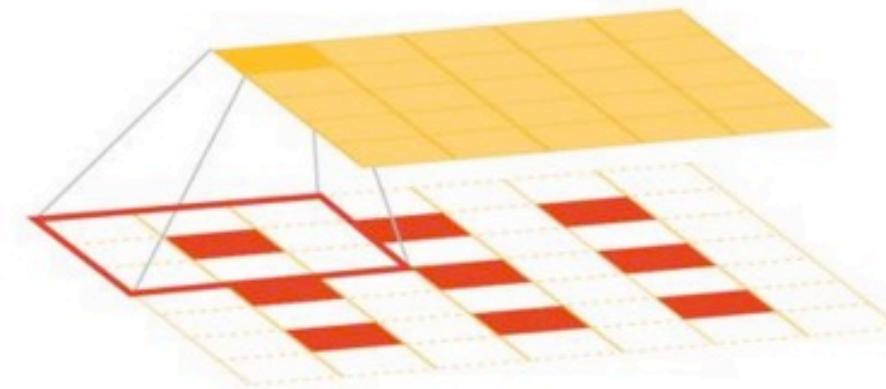
优点：当存在非常大型的数据集、大量特征和复杂的分类任务时，卷积神经网络是非常有用的

场景举例：图像识别、文本转语音、药物发现

扩展阅读：[《专栏 | 卷积神经网络简介》](#)、  
[《从入门到精通：卷积神经网络初学者指南》](#)、  
[《解析深度卷积神经网络的 14 种设计模式》](#)

## ***Convolutional neural networks***

Convolutions are blends of weights from a subsequent layer that are used to label the output layer.



Source: Algobeans, 2016

### Advantages

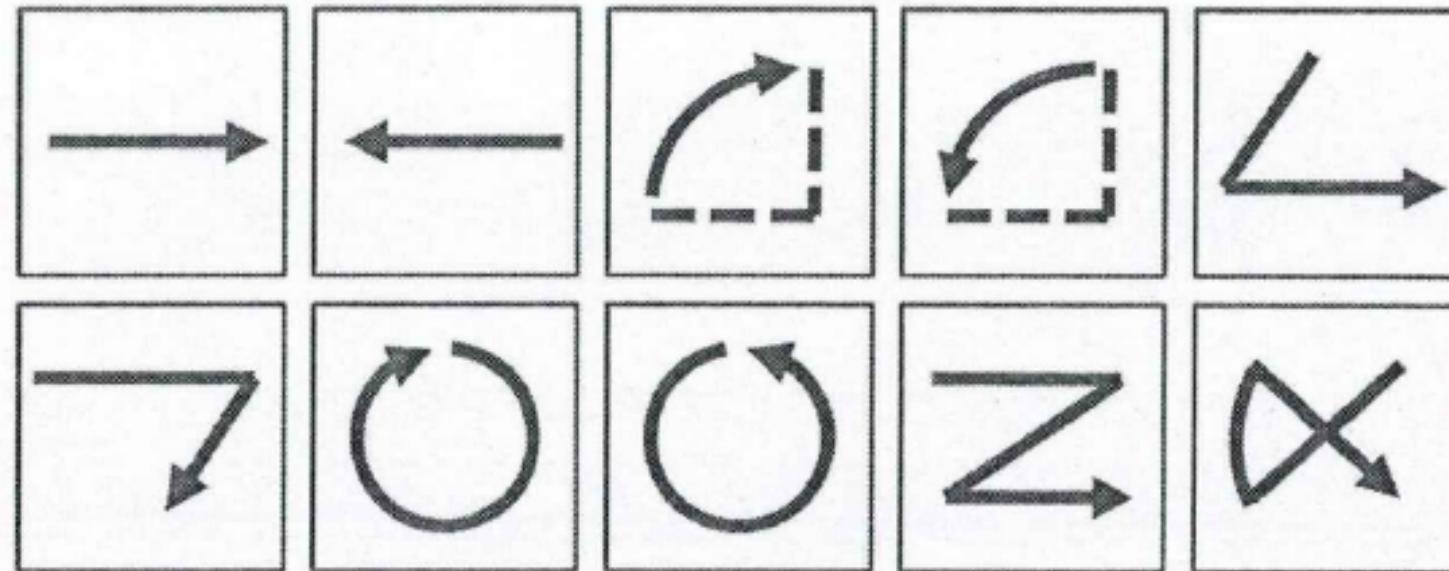
Convolutional neural networks are most useful with very large data sets, large numbers of features, and complex classification tasks.

### Use cases

Image recognition, text to speech, drug discovery

# 基于机器学习的手势识别技术—动态轨迹手势识别

- 可以实时的识别定义的10个不同的运动轨迹，依次为：右移、左移、上旋转、下旋转、下右、右下、顺时针、逆时针、Z字形、交叉

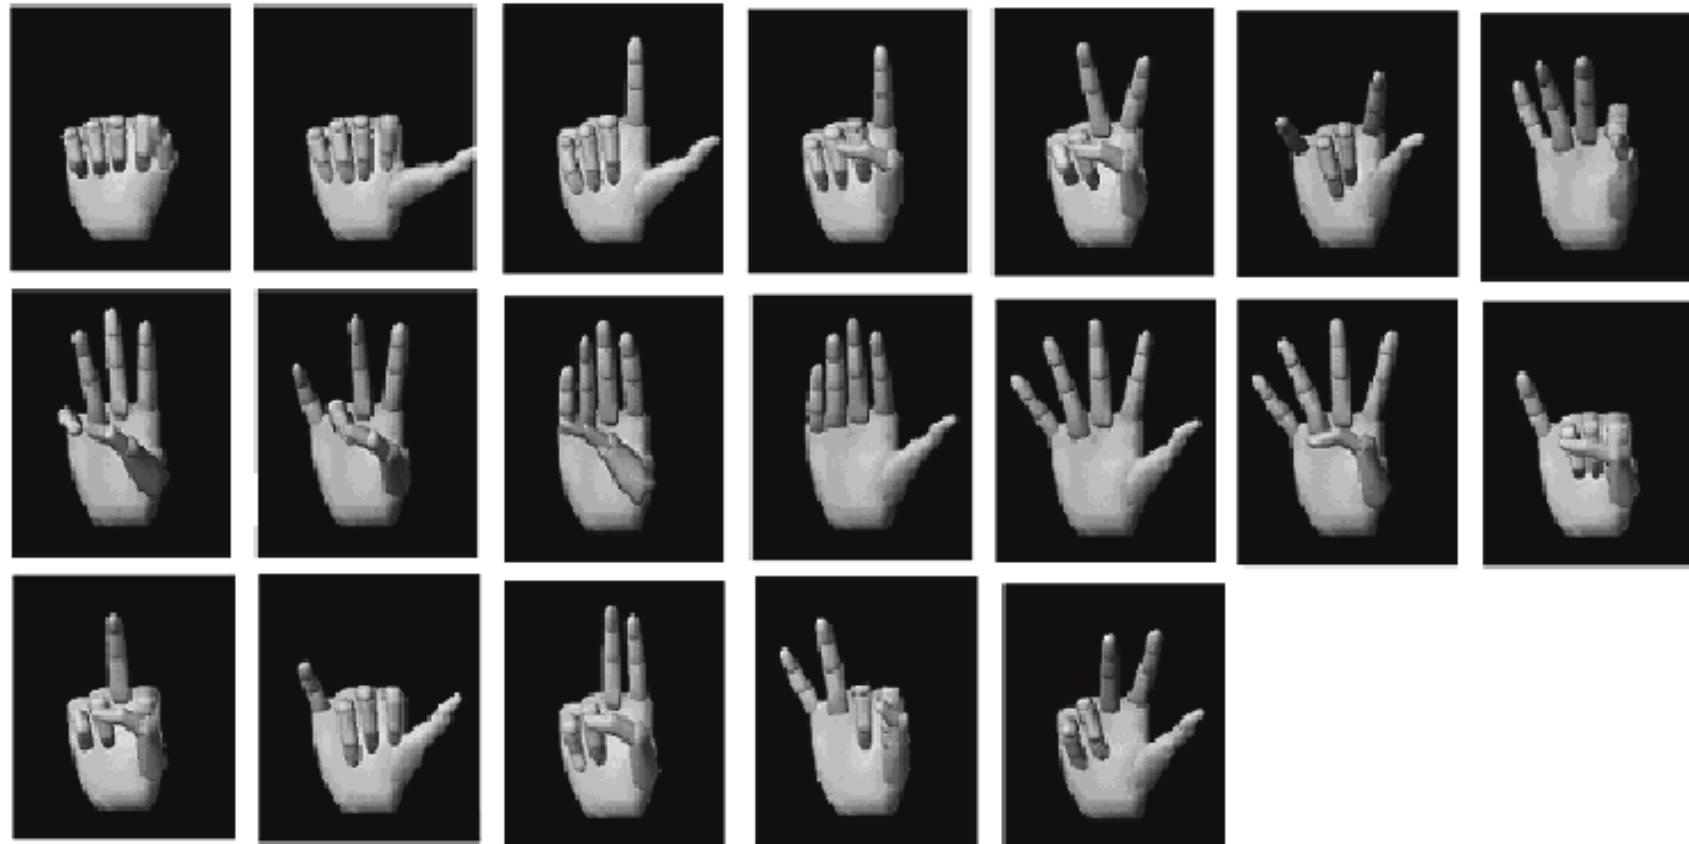


动态轨迹手势模板库

(依次为) 右移，左移，上旋转，下旋转，下右，右下，顺时针，逆时针，Z字形，交叉

# 基于机器学习的手势识别技术—静态的交互手形识别

- 可以实时的识别选取的19种常用交互手势



# 基于机器学习的手势识别技术—3D手模型的识别与跟踪

- 精确的 3D 手建模：

可以建立精确的手 3D 模型，每个手指包含 3 个关节点，形成一个可任意运动的 3D 手模型

- 3D 手模型的识别与跟踪：

有了精确的 3D 手模型后，就能实时地对精确 3D 手模型进行跟踪了，得到任意时刻的 3D 手各个关节点，从而完成3D手势识别。

# 图像处理-机器学习总结

## 一、课程及书单

课程：

图像处理、矩阵论、模式识别、机器学习、最优化、凸优化、高性能计算

书单：

- 1、数字图像处理的MATLAB实现（第2版）（国外计算机科学经典教材）（美）冈萨雷斯，（美）伍兹 著，阮秋琦 等译 /2011-06-01 /电子工业出版社
- 2、数字图像处理（第三版）(美)冈萨雷斯 等著，阮秋琦 译 /2013-04-01 /清华大学出版社  
这两本书的知识点比较全面，可根据需求有针对性的看，比如，做分割的时候主要看分割的方法：阈值法，分水岭、水平集、区域生长法等。
- 3、矩阵论（修订版）第四版 程云鹏，徐仲 编著 /2013-09-01 /西北工业大学出版社  
图像处理中，范数、奇异值分解、矩阵求逆、广义逆等知识经常用。
- 4、模式识别（第三版）（新编《信息、控制与系统》系列教材）张学工 编著 /2010-08-01 /清华大学出版社，很经典的教材。

# 图像处理-机器学习总结

## 一、课程及书单

课程:

图像处理、矩阵论、模式识别、机器学习、最优化、凸优化、高性能计算

书单:

5、统计学习方法 李航 编著 清华大学出版社

机器学习这方面的书非常多，选一本看看

6、最优化理论与算法（第2版）作者:陈宝林 编著 出版社:清华大学出版社 出版时间:2005年10月  
上课教程，个人感觉9-12章可重点学习。分别是：一维搜索、使用导数的最优化方法（最速下降、牛顿法、拟牛顿法、共轭梯度法、最小二乘等）、无约束最优化的直接方法、可行性方法

7、凸优化 鲍德 (Stephen Boyd) Lieven Vandenberghe 著, 王书宁, 许鋆, 黄晓霖 译 /2013-01-01 /清华大学出版社

有难度，可选课学习，北邮庄伯金老师这门课讲的不错

8、GPU高性能编程CUDA实战（美）桑德斯著，聂雪军等译 /2011-01-01 /机械工业出版社  
比较基础，易懂，书不厚

# 计算机视觉、机器学习、模式识别、 图像处理领域国内外期刊、会议汇总

重要国际期刊

一、 IEEE Transactions on Pattern Analysis and Machine Intelligence (PAMI)

(IEEE模式分析  
与机器智能汇刊)

链接: <http://ieeexplore.ieee.org/xpl/RecentIssue.jsp?punumber=34>

二、 IEEE Transactions on Image Processing(IP)(IEEE图像处理汇刊)

链接: <http://ieeexplore.ieee.org/servlet/opac?punumber=83>

三、 Computer Vision and Image Understanding(CVIU)(计算机视觉与图像理解)

链接: <http://www.journals.elsevier.com/computer-vision-and-image-understanding/>

四、 Artificial Intelligence(AI)(人工智能)

链接: <http://www.journals.elsevier.com/artificial-intelligence/>

五、 Pattern Recognition(PR)(模式识别)

链接: <http://www.sciencedirect.com/science/journal/00313203>

# 计算机视觉、机器学习、模式识别、 图像处理领域国内外期刊、会议汇总

重要国际期刊

## 六、Machine Learning

链接: <http://link.springer.com/journal/10994>

## 七、Data Mining and Knowledge Discovery

链接: <http://link.springer.com/journal/10618>

## 八、Journal of Machine Learning Research

链接: <http://www.jmlr.org/>

## 九、IEEE Transactions on Neural Networks

链接: <http://ieeexplore.ieee.org/xpl/RecentIssue.jsp?reload=true&punumber=72>

# 计算机视觉、机器学习、模式识别、 图像处理领域国内外期刊、会议汇总

重要国际会议

## 一、 Siggraph

链接: <http://www.siggraph.org/>

## 二、 International Conference on Computer Vision (ICCV)

## 三、 IEEE Conference on Computer Vision and Pattern Recognition(CVPR)

## 四、 European Conference on Computer Vision(ECCV)

链接: <http://www.cvpapers.com/index.html>

## 五、 Advances in Neural Information Processing Systems(NIPS)

(神经信息处理系统进展大会)

## 六、 European Conference on Machine Learning and Principles and Practice of Knowledge Discovery in Databases(ECML PKDD)

(机器学习和知识发现实践欧洲会议)

## 七、 International Conference on Learning Representations(ICLR)

## 八、 ACM SIGKDD 国际会议 (简称KDD)

## 九、 International Conference on Machine Learning(ICML)

(国际机器学习大会)

# 计算机视觉、机器学习、模式识别、 图像处理领域国内外期刊、会议汇总

## 国内学术机构

一、中国图象图形学会

链接: <http://www.csig.org.cn/index.php>

二、中国计算机学会

## 国内期刊

### 1.三大学报:

《计算机学报》 链接: <http://cjc.ict.ac.cn/>

《软件学报》 链接: <http://www.jos.org.cn/ch/index.aspx>

《电子学报》 链接: <http://www.ejournal.org.cn/index.shtml>

### 2.《中国图象图形学报》

链接: <http://www.cjig.cn/jig/ch/index.aspx>

### 3.《模式识别与人工智能》

链接: [http://manu12.magtech.com.cn/Jweb\\_prai/CN/column/home.shtml](http://manu12.magtech.com.cn/Jweb_prai/CN/column/home.shtml)

### 4.《计算机辅助设计与图形学学报（CAD&CG）》

链接: <http://jcad.ict.ac.cn/>

### 5.《遥感学报》

谢谢